

Báo cáo Phân tích Dữ liệu — Datathon 2026 *The Gridbreakers*

Đội: Data Science Team — **Phiên bản:** v2 — **Ngày:** 2026-04-17 **Phạm vi dữ liệu:** 14 bảng CSV, giai đoạn 2012-07-04 → 2022-12-31 (3,833 ngày) **Mục tiêu dự báo:** Revenue hàng ngày cho 2023-01-01 → 2024-07-01 (548 ngày, sample_submission.csv)

Báo cáo này đi kèm `results/v2/eda.ipynb` (66 cells, 15 biểu đồ EDA diagnostic) và `results/v2/eda.html`. Mọi con số trích dẫn đều có trong `results/v2/metrics.json` hoặc notebook. Các biểu đồ trong báo cáo lưu tại `results/v2/images/report/`.

1. Hiểu bài toán

1.1. Mục tiêu kinh doanh

Một công ty thương mại điện tử thời trang Việt Nam cần **dự báo doanh thu thuần hàng ngày** cho 18 tháng tiếp theo để:

- Tối ưu **phân bổ tồn kho** đầu vào theo mùa và theo vùng.
- Lập kế hoạch khuyến mãi** có lợi nhuận (giảm promo "phòng thủ" vào ngày yếu).
- Quản lý **logistics toàn quốc** (capacity 3PL, đàm phán giá).
- Chuẩn bị **dòng tiền và COGS** chính xác cho finance.

1.2. Mục tiêu dữ liệu

Thành phần	Mô tả
Biến mục tiêu	Revenue (float, VND) — doanh thu thuần hàng ngày trong <code>sales.csv</code> .
Đơn vị quan sát	1 ngày = 1 dòng (univariate time-series với exogenous regressors).
Horizon	548 ngày (2023-01-01 → 2024-07-01).
Train	3,833 ngày (2012-07-04 → 2022-12-31).
Metrics	MAE, RMSE, R^2 — đánh giá đồng thời.
Integrity	10/10 foreign-key check đạt 0 orphan rows (xem notebook §1.1).

1.3. Vì sao EDA quan trọng cho forecasting?

`Revenue_t` không phải một con số đơn lẻ. Nó là output của một **chuỗi hệ thống**:

Web traffic → Sessions → Orders → Order_items × Price → Gross Revenue
Promotions (-) Returns (-) COGS (-) Inventory (gate)

EDA chất lượng cao xác lập ba thứ mà mô hình dự báo phụ thuộc vào:

- Regime / drift:** nếu phân phối train khác phân phối test, ML sẽ sai có hệ thống. Cần time-decay hoặc cắt bớt history.
- Feature hierarchy:** xếp hạng mức độ tương quan của các tín hiệu ngoại sinh để ưu tiên feature engineering.
- Mechanism gate:** hiểu rằng Revenue bị *cắt trên* (stockout) hoặc *pha loãng* (promo). Mô hình phải học cung, không chỉ học cầu.

Phần 2 tổng hợp bức tranh hệ thống. Phần 3 trình bày 8 insight then chốt; mỗi insight đều có *Claim* → *Evidence* → *Chart* → *Business interpretation* → *Forecasting implication* → *Confidence*.

2. Core Narrative

Đây không phải bài toán dự báo chuỗi thời gian đơn thuần. Đây là một hệ sinh thái đang ở trong regime thấp sau năm 2019, phụ thuộc vào một danh mục duy nhất (Streetwear 80%) và một tập khách hàng lặp (75%), có promo đang "pha loãng" doanh thu, và đang bị nghẽn cả hai đầu — vừa thiếu hàng hot, vừa tồn hàng cold.

Ba thay đổi so với hình dung ban đầu của doanh nghiệp:

- Cú sụt 2019 là regime change, không phải COVID. Daily revenue trung bình giai đoạn 2019–2022 thấp hơn 40.5% so với 2012–2018 ($t=28.6$, $p < 10^{-162}$, Cohen $d = 0.89$). Cú giảm nặng nhất đã xảy ra trong năm 2019 — trước khi Việt Nam có ca COVID đầu tiên (23/01/2020).
- Mùa cao là Tháng 4–6, không phải Q4. Tháng 5 cao nhất (mean daily +53.4% so grand daily mean 10 năm); Tháng 12 (−41.1%) và Tháng 1 (−39.6%) là đáy. Tập test bao gồm 2 mùa cao (Q2/2023, Q2/2024) và 2 mùa thấp (Q1/2023, Q4/2023–Q1/2024) → baseline seasonal-naïve sẽ chiếm phần lớn R^2 .
- Promo đang hoạt động phòng thủ, không tấn công. Ngày có >50% đơn dùng promo có median doanh thu thấp hơn 13.4% so với ngày promo nhẹ (Mann-Whitney U, $p = 9.7 \times 10^{-13}$). Chiều quan hệ ngược với trực giác marketing.

Hai phát hiện cơ cấu sâu hơn:

- Rủi ro tập trung danh mục: Streetwear chiếm 80.1% doanh thu (HHI category = 0.665). Một shock vào line này = shock toàn doanh nghiệp.
- Paradox tồn kho: trong 12 tháng gần nhất, stockout và overstock cùng lúc ở mức cao (60–70% và 68–87%) trên các SKU khác nhau → mis-allocation, không phải thiếu tổng cung.

Từ đó, phần 3 xếp hạng 8 insight theo mức độ tác động đến bài toán dự báo và đến quyết định kinh doanh.

3. Các insight then chốt

Insight 1 — Regime break 2019: daily mean giảm 40.5% trước COVID

Claim. Phân phối doanh thu giai đoạn 2012–2018 khác rõ rệt so với 2019–2022. Sự kiện phá vỡ xảy ra trong 2019, không phải 2020 (COVID).

Evidence.


Năm	Revenue (triệu VND)	YoY %	Gross margin
2016	2,104.6	+11.4%	15.4%
2017	1,911.2	−9.2%	11.3%
2018	1,850.1	−3.2%	16.6%
2019	1,136.8	−38.6%	11.6%
2020	1,054.5	−7.2%	16.0%
2021	1,043.0	−1.1%	9.8%
2022	1,169.7	+12.1%	12.8%

Welch t-test, 2012–2018 vs 2019–2022:

- pre mean = 5,070,141 VND/ngày; post mean = 3,014,444 VND/ngày
- drop = **40.5%**; $t = 28.57$; $p \approx 7.6 \times 10^{-163}$; Cohen d = **0.89** (effect size lớn).

Lưu ý đơn vị. Toàn bộ doanh thu dataset = 16,430 triệu VND (~16.4 tỷ) cho 10.5 năm — đây là tập dữ liệu mô phỏng với scale nhỏ; các hành động khuyến nghị nên được quy ra % để khi scale-up dữ liệu thật vẫn áp dụng được.

Chart. [images/report/revenue_regime_change.png](#) — MA30/MA365 với vùng regime break 2019 (cam) và mốc COVID-19 Việt Nam (tím gạch đứt).



Business interpretation. Có một thay đổi cấu trúc (đổi vendor, mất market share, thay đổi định vị, thu hẹp danh mục...) trong 2019 kéo mức sản doanh thu xuống ~1,100 triệu VND/năm. 2022 (+12.1%) gợi ý phục hồi nhẹ chứ không quay lại đỉnh 2016.

Recommended action. Root-cause cú sụt 2019 với team thương mại: event log, vendor changes, category drop. Xác định liệu regime thấp là tạm thời hay vĩnh viễn.

Forecasting implication. Train trên toàn bộ 10.5 năm với trọng số đều nhau sẽ *overestimate* doanh thu 2023. Giải pháp:

1. Cắt train về **2019-01** → **2022-12** (4 năm = ~1,460 ngày, đủ để học 4 chu kỳ năm).
2. Hoặc dùng **time-decay weight** $w_t = \exp(-\lambda \cdot \text{age_years})$ với $\lambda \approx 0.3-0.5$.
3. Thêm feature binary **is_post_regime** cho mô hình học được bias offset.

Confidence. High — test thống kê rất mạnh ($p < 10^{-162}$), effect size lớn, visible rõ trên MA365.

Insight 2 — Mùa cao là Tháng 5 (+53%), Tháng 12-1 là đáy (-40%)

Claim. Trục giác "Q4 là cao điểm thời trang" sai với thương hiệu này. Cao điểm doanh thu nằm ở **Q2 (Tháng 4-6)**, thấp điểm ở **cuối Q4 + đầu Q1**.

Evidence. Revenue trung bình theo tháng (VND/ngày):


Tháng	1	2	3	4	5	6	7	8	9	10	11	12
Mean	2.59M	3.48M	4.93M	6.53M	6.58M	6.43M	4.66M	4.44M	3.80M	3.30M	2.61M	2.52M

Top 3 ô (thứ × tháng) lệch mean ngày nhiều nhất (% so mean 10 năm):

- Thứ Năm × Tháng 5: **+89.9%**
- Thứ Tư × Tháng 5: +81.6%
- Thứ Tư × Tháng 4: +78.5%

Đáy: Thứ Sáu × Tháng 12 = -45.8%; Thứ Năm × Tháng 1 = -45.1%.

Chart. [images/report/seasonality_month_dow_heatmap.png](#)



Business interpretation. Đặc thù danh mục Streetwear + Outdoor (chiếm 95% doanh thu, xem Insight 3) đẩy mùa cao vào nửa đầu hè. Cuối năm là low-season — ngược với nhận định trực giác về Tết/Black Friday. Pattern này **lặp lại đều đặn 10 năm** → là cấu trúc, không phải ngẫu nhiên.

Recommended action. Re-brief team marketing: dời ngân sách paid ads + promo chủ động vào Tháng 4–6. Đừng đổ vào Tháng 12.

Forecasting implication. Baseline seasonal-naïve (dùng Revenue cùng ngày năm trước) sẽ bắt được phần lớn tín hiệu này. Giá trị gia tăng của ML nằm ở:

- Ngày chuyển mùa (tháng 3 → 4, tháng 6 → 7).
- Ngày promo + ngày Tết dương/âm (cần ground-truth calendar).
- Features đề xuất: `month`, `dow`, `week_of_year`, `month × dow`, `Fourier(7)`, `Fourier(365.25)`.

Confidence. High — pattern nhất quán qua cả 10 năm, đủ dữ liệu ở mỗi ô 7×12.

Insight 3 — Streetwear 80% doanh thu: rủi ro tập trung cực cao (HHI = 0.665)

Claim. Doanh nghiệp là **công ty Streetwear về bản chất kinh tế**, không phải nhà bán lẻ thời trang đa danh mục. Một shock vào line này tương đương shock toàn công ty.

Evidence.


Category	Revenue (triệu VND, 2012–2022)	Share
Streetwear	12,558	80.1%
Outdoor	2,353	15.0%
Casual	440	2.8%
GenZ	329	2.1%

HHI category = **0.665** (thang 0.25 = cân bằng hoàn hảo 4 cat, 1.0 = độc quyền). Mức này vượt xa ngưỡng FTC coi là "highly concentrated" (0.25).

Segment cũng tập trung: Everyday (32.8%) + Balanced (31.3%) = **64.1%** doanh thu (trên 8 segments).

Chart. [images/eda/09_revenue_by_category_segment.png](#) (trong notebook).

Category mùa vụ khác nhau. Từ heatmap [images/report/category_monthly_seasonality.png](#):



- **Streetwear:** peak Tháng 5 (13.5%), 4 (12.2%); đáy Tháng 12 (3.5%).
- **GenZ:** peak Tháng 6 (14.7%) + Tháng 8 (14.2%); *muộn hơn* Streetwear 1 tháng.
- **Outdoor:** flat (9–10% mỗi tháng); peak *Tháng 12* (10.1%) vì đồ lạnh.
- **Casual:** peak Tháng 5 (13.1%).

Business interpretation. Nếu định nghĩa "bài toán dự báo" ở level tổng, bạn đang ngằm dự báo doanh thu Streetwear. Điều đó có thể đủ cho KPI tài chính, nhưng không giúp tối ưu tồn kho cho 3 cat còn lại.

Recommended action.

- Kiểm tra chiến lược đa dạng hóa: 2.8% Casual sau 10 năm là quá thấp — hoặc dừng đầu tư, hoặc gấp 3 ngân sách.
- Theo dõi **leading indicator** cho Streetwear (giả định feature trọng yếu nhất cho Revenue tổng).

Forecasting implication. Có thể cải thiện mô hình bằng cách:

1. Dự báo Revenue Streetwear và Revenue-còn-lại **riêng** rồi cộng (hierarchical forecasting).
2. Thêm feature `category_mix_share_streetwear_last_30d` — nếu tỷ trọng này đổi, aggregate revenue cũng đổi.
3. Thử BottomUp từ product-level hoặc TopDown + reconciliation (MinT).

Confidence. High — tỷ lệ 80.1% là hard fact.

Insight 4 — Promo đang "phòng thủ" chứ không "tấn công": ngày promo dày có median doanh thu thấp hơn 13.4%

Claim. Hypothesis "tăng promo → tăng doanh thu" không được dữ liệu hỗ trợ ở mức daily aggregate. Thực tế là ngày promo dày có doanh thu thấp hơn.

Evidence. Chia ngày theo % đơn có dùng promo:


Bucket (% đơn có promo)	Số ngày	Mean Revenue	Median Revenue
<10%	2,158	4,539,464	3,824,290
10-25%	59	4,800,759	4,361,415
25-50%	181	4,086,724	3,596,036
>50%	1,435	3,910,364	3,313,899

Kiểm định Mann-Whitney U (light <10% vs heavy >50%):

- Median light = 3,824,290; median heavy = 3,313,899 → **heavy thấp hơn 13.4%** (công thức $(\text{light} - \text{heavy}) / \text{light}$, chia cho baseline là light).
- $U = 1,765,634$; $p = 9.7 \times 10^{-13}$ → khác biệt rất khó do ngẫu nhiên.

Ở mức panel tổng, `promo_share` có Spearman = **-0.11** với Revenue — âm, nhẹ. `total_discount` có $\rho \approx +0.02$ (gần 0).

Chart. `images/report/promo_share_vs_revenue.png`



Business interpretation. Ba cách diễn giải khả dĩ (không loại trừ nhau):

1. **Reverse causality** — marketing đẩy coupon khi dự đoán ngày yếu (phòng thủ).
2. **Cannibalization** — giảm giá cho khách đã định mua; không kéo thêm khách mới.
3. **Discount depth quá sâu** — margin 2021 = 9.8% (thấp nhất 10 năm) trùng với giai đoạn promo dày.

Giả thuyết 1 được củng cố bởi Spearman âm nhưng rất nhẹ (-0.11): promo không "gây" doanh thu thấp, mà *đi kèm* ngày thấp.

Recommended action.

- **A/B test:** chỉ chạy promo vào ngày dự báo thấp hơn ngưỡng (pre-emptive lift), không dàn trải. Đo uplift thật bằng quasi-experiment (synthetic control).
- Re-negotiate **discount_value** với team commercial: 13.4% gap ở median có thể đang *trả* cho marketing để che đậy tuần yếu.

Forecasting implication.

- `promo_share_t` làm exogenous feature được, nhưng **không dùng làm "driver" nhân quả**. Với mô hình ML, promo có thể bị gán hệ số âm nếu không có control cho seasonality.
- Thêm `promo_share_t-7` và `total_discount_t-7` cho lag effect (khách canh promo từ ngày trước).

Confidence. Medium-High — p-value rất mạnh cho *tương quan*, nhưng correlation $\neq$ causation. Uplift thật cần experiment.

Insight 5 — Paradox tồn kho: stockout và overstock đồng thời cao

Claim. Tồn kho bị **phân bố sai** chứ không thiếu tổng cung. SKU hot thì hết, SKU cold thì ế — cùng lúc, mọi tháng.


Evidence. 12 tháng 2022 (từ `metrics.json`, xem chi tiết notebook S9):

Tháng	Stockout %	Overstock %	Fill rate
2022-01	58.3%	82.0%	96.9%
2022-04	70.2%	68.2%	95.8%
2022-07	69.3%	74.9%	96.5%
2022-10	65.5%	85.8%	96.2%
2022-11	69.7%	87.0%	96.0%
2022-12	67.2%	80.4%	96.1%

Spearman (monthly aggregate) với Revenue tháng:

- `stockout_rate` vs Revenue: $\rho = +0.21$ (stockout cao khi tháng cao — logical: nhu cầu cao hơn năng lực)
- `overstock_rate` vs Revenue: $\rho = -0.65$ (tháng thấp $\rightarrow$ ế nhiều)
- `mean_fill_rate` vs Revenue: $\rho = -0.49$ (fill-rate giảm khi mùa cao)

Chart. `images/report/inventory_health_monthly.png`



Business interpretation. Fill-rate 96% "đẹp trên giấy" nhưng 70% SKU hết hàng — khác biệt vì fill-rate tính trên đơn đã nhận, không tính khách bỏ đi vì không có size/màu. Nếu giải được mis-allocation, **upside doanh thu có thể 10–15%** (nhu cầu bị censor).

Recommended action.

- SKU $\times$ region $\times$ month demand forecasting thay vì tổng một khối.
- Giảm overstock cho 4 cat ngoài Streetwear (đang chiếm 15–20% overstock).
- KPI mới: fill-rate *by intent* (đo traffic đến page hết hàng) thay vì fill-rate đã-thành-đơn.

Forecasting implication.

- **Revenue_t** bị **censored**: true demand > observed revenue khi stockout cao.
- Thêm features: **stockout_rate_t-30**, **overstock_rate_t-30**, **days_of_supply_t-30** làm control variable.
- Cần thận với mô hình học sự kiện stockout như "ngày low" — có thể dùng Tobit regression hoặc hai-stage (predict demand → cap by inventory).

Confidence. High — số liệu inventory chi tiết, pattern ổn định qua 12 tháng.

Insight 6 — Orders là leading feature mạnh nhất ($\rho = 0.92$); web traffic chỉ giải thích ~14% phương sai



Claim. Feature có giá trị dự báo cao nhất là **số đơn hàng đã tạo**, không phải web traffic. Traffic chỉ là leading indicator yếu (+1 ngày, $\rho \approx 0.37$).

Evidence. Spearman với Revenue hàng ngày (panel 3,833 × 15):

Feature	ρ với Revenue
COGS	+0.972
n_orders	+0.923
overstock_rate (lag 30d)	-0.497
refund	+0.451
mean_fill_rate (lag 30d)	-0.376
unique_visitors	+0.369
sessions	+0.368
page_views	+0.351
margin	+0.171
stockout_rate	+0.160
promo_share	-0.114
bounce_rate	-0.016

Lead-lag traffic → revenue (cửa sổ ±7): peak ở **lag +1** ($\rho = 0.373$ vs $\rho = 0.368$ tại lag 0). Traffic hôm qua dự báo doanh thu hôm nay tốt hơn traffic cùng ngày — nhưng chỉ tăng 0.005 ρ .

Chart. [images/report/exogenous_signal_ranking.png](#) + [images/report/webtraffic_vs_revenue.png](#)



Business interpretation.

- COGS** gần như colinear với Revenue ($R^2 = 0.953$ trong OLS, slope = 1.154) vì margin ổn định. Dùng COGS làm regressor là data leakage (COGS cũng cần dự báo).
- n_orders** là biến trung gian tốt: **nếu ta dự báo n_orders** → **AOV × n_orders = Revenue** (AOV median = 26,715 VND).
- Traffic giải thích ~13.6% phương sai ($p^2 \approx 0.136$); **bounce_rate** và **avg_session_duration** gần 0 → **chất lượng session không tương quan** với doanh thu. Có thể mô hình kinh doanh dựa vào khách quay lại (75% repeat-rate, xem Insight 7).
- Traffic theo **traffic_source** sau khi pivot có $p < 0.05$ cho từng kênh — bị *dilute* khi chia nhỏ. Có thể do mỗi kênh chỉ đóng góp cho một phần nhỏ đơn hàng, hoặc **traffic_source** là session-level không theo order.

Recommended action.

- Xây dựng **two-stage model**: Stage 1 dự báo daily orders, Stage 2 dự báo AOV (hoặc cả hai đồng thời với joint loss).

- Đo uplift paid media thật bằng experiment — **đừng** suy ra từ $\rho = 0.37$.

Forecasting implication. Danh sách feature ưu tiên (tránh leakage):

Nhóm	Features	Lý do
Calendar	<code>dow, month, week_of_year, is_holiday_vn</code> , Fourier(7, 365.25)	Seasonality (Insight 2)
Lag target	<code>Revenue_lag_{7, 14, 28, 365}</code> , rolling mean 30/90	Autoregressive
Orders	<code>n_orders_lag_{1, 7}</code> , <code>active_customers_30d</code>	$\rho = 0.92$ với target
Web	<code>sessions_lag_1, unique_visitors_lag_1</code>	Leading 1 ngày ($\rho = 0.373$)
Inventory	<code>stockout_rate_lag_30, overstock_rate_lag_30</code>	Demand censoring
Promo	<code>promo_share, total_discount_lag_7</code>	Control, không phải driver
Refund	<code>refund_lag_30</code>	Ảnh hưởng net Revenue

Confidence. High — panel 3,833 ngày, Spearman robust.

Insight 7 — Pareto 20/60 + 75% repeat-rate: doanh thu dựa vào cohort cũ

Claim. 20% khách hàng tạo 60.7% doanh thu; 75.2% khách mua lặp. Cohort *cũ* quan trọng hơn acquisition mới.

Evidence.

Nhóm	Số khách	% Doanh thu tích lũy
Top 10%	9,025	40.0%
Top 20%	18,050	60.7%
Top 40%	36,099	83.4%
Top 80%	72,197	98.7%

- Repeat-rate (>1 đơn): **75.2%** — cao gấp 2× benchmark e-commerce VN (~30–40%).
- Orders/khách: mean 7.17, median 4.

Chart. `images/eda/08_active_vs_new_customers.png` — trong notebook; cho thấy số khách active/tháng duy trì ~2,840 người trong 12 tháng cuối train, trong khi khách mới trung bình 1,759 người/tháng (tăng gần gấp đôi về cuối). Tuy nhiên doanh thu vẫn không phục hồi bằng 2016 → **khách mới chất lượng kém hơn cohort cũ**, hoặc bị pha loãng bởi customer churn ẩn.

Business interpretation.

- Tỷ lệ repeat 75% là tài sản cạnh tranh, nhưng đồng thời là rủi ro: nếu cohort 2012–2018 rời bỏ, 60% doanh thu mất.
- Kết hợp với Insight 1 (sụt 2019): có khả năng 2019 là thời điểm **mất cohort cốt lõi** hoặc *mất kênh acquisition* — cần phân tích cohort retention theo năm signup (out of scope v2).

Recommended action.

- VIP retention cho top 20%: early-access drops, loyalty tier, dedicated CS.
- Monitor **cohort retention curve** theo năm signup để phát hiện sớm churn bất thường.

Forecasting implication.

- Feature `active_customers_last_30d` và `active_VIP_customers_last_30d` có thể là exogenous mạnh (tương tự Insight 6 nhưng ổn định hơn `n_orders` vì ít nhiễu).
- Cần thận với **leakage**: `active_customers_last_30d` tại ngày `t` phải được tính chỉ từ orders trước ngày `t`.

Confidence. Medium-High — Pareto number là fact; liên kết cohort → regime break là giả thuyết chưa chứng minh (correlation).

Insight 8 — Wrong size là 35% lý do trả hàng; delivery-time gần như không ảnh hưởng rating

Claim. Vấn đề CX lớn nhất là **size chart**, không phải tốc độ giao hàng. Giảm logistics express không làm rating tệ hơn.

Evidence.

Phân phối `return_reason` (n = 39,939):

Lý do	%
wrong_size	35.0%
defective	20.1%
not_as_described	17.6%
changed_mind	17.4%
late_delivery	10.0%

Return-rate đồng đều giữa category (3.26–3.52%), refund/doanh thu ≈ **3.15%** mỗi tháng.


Rating vs delivery days (ANOVA, F = 2.83, p = **0.037**):

Bucket delivery	n	Mean rating	% ≤ 2★
0–2	18,990	3.940	13.1%
3–4	37,638	3.948	12.7%
5–6	38,036	3.924	13.4%
7–9	18,887	3.932	13.1%

Khác biệt rating có ý nghĩa thống kê (p = 0.037) nhưng **effect size tầm thường**: mean 3.948 vs 3.924 = chênh 0.024 điểm trên thang 5, không đủ để thay đổi quyết định logistics.

Delivery-days thực tế dao động 2–7 ngày (median 4), không có dữ liệu express thực sự (0–1 ngày).

Chart. [images/report/delivery_vs_rating.png](#)



Business interpretation.

- Đầu tư vào **size chart / virtual try-on / size recommendation ML** có ROI cao nhất (refund Streetwear $\approx$ 407 triệu VND/10 năm $\approx$ 39 triệu VND/năm; toàn bộ refund $\approx$ 49 triệu VND/năm $\approx$ **3.15%** tỷ lệ refund/doanh thu hàng tháng).
- 3PL tier 5–7 ngày cho rating tương đương 2–4 ngày $\rightarrow$ *không trả thêm* cho express.

Recommended action.

- Triển khai size chart có **gender + age_group** tham chiếu thay vì size chart duy nhất.
- A/B test virtual try-on trên top SKU Streetwear.
- Re-negotiate 3PL contract — dời volume sang economy tier.

Forecasting implication.

- **refund** (cùng ngày) có Spearman +0.45 với Revenue (panel Insight 6) — giải thích khả dĩ: ngày cao mùa $\rightarrow$ nhiều đơn $\rightarrow$ nhiều refund đến hạn rơi vào cùng giai đoạn. **Đây là correlation, không causation** $\rightarrow$ không được dùng refund để "tăng" predicted revenue. Nên lag refund (**refund_lag_30**) để tránh leakage trong mô hình.
- Features shipping không đáng thêm vào mô hình Revenue tổng (tín hiệu yếu).

Confidence. Medium — wrong-size là fact; claim về 3PL cost saving cần cost breakdown thực tế.

Insight 9 — Horizon 548 ngày = 14.3% độ dài train; rolling-origin CV là bắt buộc

Claim. Test range gấp rưỡi chu kỳ năm. Random k-fold hoặc hold-out ngắn sẽ **cho overfit signal giả**. Validation phải mô phỏng đúng horizon.

Evidence.


- Train: 3,833 ngày (2012-07-04 $\rightarrow$ 2022-12-31), không có gap.
- Test: 548 ngày (2023-01-01 $\rightarrow$ 2024-07-01).
- Ratio = 14.3% độ dài train.
- Horizon vượt 1 chu kỳ năm (365 ngày), vào **năm 2** (2024) — không có ground-truth xa gần đó.

Doanh thu quý gần đây (triệu VND):

Quý	Revenue (triệu)
2021Q2	406.4
2022Q2	416.1 (+2.4%)
2022Q4	179.8

Q2/2023 có thể ~425–450 triệu nếu tiếp tục +2 đến +8% YoY; Q4/2023 ~160–200 triệu. Biên độ Q2 vs Q4 ~2.5× là rủi ro metric (R^2 biến thiên theo variance của y).

Chart. [images/report/quarterly_revenue_with_test_horizon.png](#)



Business interpretation. Không thuộc phạm vi kinh doanh — thuộc methodology.

Recommended action (pipeline forecasting).

- Rolling-origin CV:**
 - Fold 1: train 2012-07 → 2020-06, val 2020-07 → 2021-12 (548 ngày)
 - Fold 2: train 2012-07 → 2021-06, val 2021-07 → 2022-12 (548 ngày)
- Tránh random k-fold tuyệt đối (leakage).
- Báo cáo 3 metric (MAE, RMSE, R^2) ở mỗi fold + trung bình.
- Cho tự tin thống kê: báo cáo **seasonal-naïve benchmark** ($\text{Revenue}(t-365)$) để chứng minh uplift thật.

Forecasting implication. Pipeline cuối cùng cần:

```
Step 1: feature engineering (calendar + lag + exogenous)
Step 2: rolling-origin CV (2 folds x 548 ngày)
Step 3: models ensemble (SARIMAX + LightGBM + Prophet/NeuralProphet)
Step 4: SHAP/feature importance analysis
Step 5: report MAE/RMSE/ $R^2$  + uplift vs seasonal-naïve
```

Confidence. High — độ dài là hằng số.

4. Khuyến nghị

Xếp theo **impact × feasibility × liên quan đến forecasting**.

4.1. Ưu tiên 1 — Ngay lập tức (0–1 tháng)

#	Khuyến nghị	Nguồn	Impact	Feasibility
1	Rolling-origin CV 548 ngày cho mọi mô hình; không random split.	#9	Tránh overfit, metric đúng	Cao
2	Cắt train về 2019–2022 hoặc time-decay ($\lambda \approx 0.4$).	#1	Giảm bias >10% MAE	Cao

#	Khuyến nghị	Nguồn	Impact	Feasibility
3	Review chính sách promo: ngưng dần trái, chỉ chạy khi <code>predicted_revenue < threshold</code> .	#4	13.4% gap median → khả năng phục hồi 2–4 điểm margin ≈ 23–47 triệu VND/năm (trên mức 2022)	Trung bình
4	Feature engineering baseline v1: calendar + Fourier + <code>Revenue_lag_{7,28,365}</code> + <code>n_orders_lag_1</code> + <code>refund_lag_30</code> .	#2, #6	Đủ vượt seasonal-naïve	Cao

4.2. Ưu tiên 2 — Trung hạn (1–3 tháng)

#	Khuyến nghị	Nguồn	Impact
5	Hierarchical forecast: Streetwear vs rest separately, sum up.	#3	+3–8% R ² (ước tính)
6	Root-cause cú sứt 2019 với team thương mại.	#1	Chiến lược cấp cao
7	Giải mis-allocation tồn kho (stockout 70% + overstock 80% đồng thời).	#5	Nâng trần doanh thu 10–15%
8	VIP retention top 20% khách (60% doanh thu).	#7	Bảo toàn cohort cốt lõi
9	Thêm <code>stockout_rate_lag_30</code> , <code>active_customers_30d</code> vào mô hình.	#5, #7	Capture demand censoring

4.3. Ưu tiên 3 — Dài hạn (3–12 tháng)

#	Khuyến nghị	Nguồn	Impact
10	Size chart ML / virtual try-on — 35% lý do trả là <code>wrong_size</code> .	#8	Giảm refund rate 3.15% → 2.2% = CX + giảm logistics cost (~30% của chi phí handling returns)
11	Dời marketing calendar sang Tháng 4–6 (cao điểm thật).	#2	+15–20% hiệu quả ads
12	Re-negotiate 3PL tier economy thay vì express.	#8	Tiết kiệm logistics
13	Diversification Casual/GenZ hoặc dừng đầu tư — hiện 2.1–2.8% sau 10 năm.	#3	Chiến lược danh mục

4.4. Mô hình dự báo (Part 3 Kaggle)

Architecture đề xuất:

- Baseline:** Seasonal-naïve $Revenue(t) = Revenue(t-364)$ → benchmark bắt buộc.
- Stat model:** SARIMAX(p, d, q)(P, D, Q)₇ với exogenous (promo_share, sessions_lag_1, stockout_rate_lag_30).
- ML model:** LightGBM với feature set ở §3 Insight 6 + calendar + Fourier.
- Ensemble:** trung bình có trọng số 3 mô hình (tìm trọng số bằng CV).
- Dự báo COGS:** dùng $COGS = Revenue \times rolling_margin_{90d}$ (margin ổn định, std = 12.7%, median 17.8%).

Validation metrics (bắt buộc report):

- MAE, RMSE, R² cho mỗi rolling fold.
- Uplift % vs seasonal-naïve.
- SHAP top-10 feature importance.

5. Giới hạn & rủi ro

5.1. Dữ liệu

Vấn đề	Ảnh hưởng	Mitigation
<code>sales.csv</code> chỉ có <code>Date</code> , <code>Revenue</code> , <code>COGS</code> — không breakdown theo SKU/region.	Phải reconstruct từ <code>orders</code> + <code>order_items</code> ; có thể không khớp 100% do returns/adjustments.	Validate tổng reconstruct vs <code>Revenue</code> ; dùng <code>sales.csv</code> là ground-truth.
Missing cao: <code>order_items.promo_id_2</code> 99.97%, <code>order_items.promo_id</code> 61.3%, <code>promotions.applicable_category</code> 80%.	Promo features sparse.	Treat missing as "no promo" (đã làm trong notebook §7).
<code>promotions</code> chỉ có 50 campaigns / 10 năm → thừa.	Khó mô hình hóa promo uplift cá nhân.	Aggregate về <code>promo_share</code> ở daily level.
<code>conversion_rate</code> bị loại khỏi <code>web_traffic.csv</code> (note.md).	Mất một tín hiệu.	Tự tính <code>n_orders/sessions</code> nếu cần.
Regime break 2019 (Insight 1).	Phân phối train ≠ test.	Time-decay / cut train (Rec 2).
Stockout censor (Insight 5).	Observed < true demand khi stockout cao.	Thêm <code>stockout_rate</code> làm control.
Không có external data: thời tiết VN, tỷ giá, CPI, Tết âm lịch, lễ 30/4, 2/9.	Mất tín hiệu bên ngoài.	Có thể thêm calendar Tết âm + nhiệt độ TP.HCM/HN nếu được phép.

5.2. Phân tích / mô hình

- **Correlation ≠ causation**, đặc biệt Insights 4 (promo), 5 (inventory), 6 (traffic). Uplift thật cần experiment, không có A/B trong dataset.
- **Self-selection bias trong reviews** (Insight 8): ~20% đơn delivered có review (113,551 / ~566k); khách bất mãn nặng có thể churn thay vì để 1 ★ → rating là thước đo một phía.
- **R² trong time-series**: predict gần mean → R² dương nhỏ; so sánh với seasonal-naïve là bắt buộc.
- **Leakage risks chính**:
 - Dùng `COGS_t` làm feature (đã loại vì COGS cũng là target gián tiếp).
 - Dùng `orders_t` làm feature mà không lag (orders cùng ngày = gần như Revenue).
 - Dùng inventory snapshot tháng t cho predict tháng t (dùng lag 30 ngày tối thiểu).
 - Train rolling stats không respecting time order.
- **548-day horizon** vượt 1 chu kỳ năm: dự báo nửa sau 2024 sẽ có CI rộng; nên report prediction interval.

5.3. Ethics & practicality

- Dataset có PII nhạy trung bình: `zip` + `gender` + `age_group` + `signup_date` có thể re-identify ở thành phố nhỏ. Đề xuất hash `zip` nếu public.
- **Promo targeting bias**: nếu mô hình đề xuất promo theo `age_group/gender`, có thể loại trừ khách null (bias). Kiểm tra fairness parity trước khi deploy.
- **Imbalance region**: East (46.5% doanh thu), Central (30.1%), West (23.4%). Mô hình tổng không bị ảnh hưởng, nhưng allocation tồn kho theo mô hình sẽ under-serve miền Tây.

5.4. Rủi ro competition

- Test range 2023-01 → 2024-07 có thể "giống 2022" mạnh → **rủi ro overfit seasonal-naïve**. Leaderboard shake-up nếu 2023 có shock khác.
- 12 điểm leaderboard / 20 điểm Part 3 → **8 điểm từ pipeline + CV + SHAP**. Báo cáo kỹ thuật chặt chẽ quan trọng ngang hiệu suất.

Phụ lục — File nguồn

File	Mô tả
results/v2/eda.ipynb	66 cells, 15 biểu đồ EDA diagnostic (images/eda/).
results/v2/eda.html	Export HTML của notebook.
results/v2/metrics.json	Toàn bộ số liệu trích dẫn trong báo cáo.
results/v2/images/eda/	15 ảnh EDA (01–15).
results/v2/images/report/	9 ảnh insight-focused.
results/v2/build_notebook.py	Script reproduce notebook (idempotent).

So với v1. v2 bổ sung:

1. Statistical validation cho mọi insight (t-test, Mann-Whitney, ANOVA, linear regression).
2. Exogenous feature ranking (Spearman panel) — không có trong v1.
3. Lead-lag traffic analysis — chứng minh traffic chỉ lead 1 ngày.
4. Hierarchical view theo category với mùa vụ khác nhau.
5. Paradox tồn kho có số mới (stockout + overstock đồng thời).
6. Size chart là thủ phạm chính (35% return reason) — có số thay vì giả định.

Kết luận Gridbreaker. Ba insight phá pattern mạnh nhất: **(1)** cú sụt 2019 *trước* COVID ($t=28.6$, $p<10^{-162}$); **(2)** promo đang phòng thủ không tấn công (heavy < light 13.4% median, $p<10^{-12}$); **(3)** mùa cao là Tháng 5 không phải Q4 (+90% vs −46% ở ô đối cực). Mỗi insight đều dẫn tới một hành động cụ thể, có thể đo bằng tiền hoặc cải thiện mô hình — đúng tinh thần *System Thinking* → *Break Patterns* → *From Insight to Direction*.